A-123 전이학습 (456 → A-123) 결과 보고서

2026-11-04 · 김혜연 · preregistration.md v0.2.2 5절 기준 · 결과 PR #25 (실행 커밋 9947b4c, 2026-11-01)
입력: results/2026-11-01_김혜연_FV1_a123_transfer_{folds, stats, judgment, rho}.csv, results/diagnostics/2026-11-01_김혜연_{gp_warnings, t2_decomposition}.csv. 숫자는 전부 이 파일에서 다시 계산했다.

1. 요약

질문: 라벨이 전부 공개된 456 그룹(A-456, B-456)의 소스 모델을 A-123으로 옮기면, A-123 라벨이 일부(2~16%)만 공개된 조건에서 A-123 단독 모델보다 MRR 예측이 좋아지는가?

결론: 주 판정(공개 8%, T3 대 T1)은 S1·S2 모두 통과하지 못해 "효과 없음 (기본값 T1 유지)"이다. 456에서 학습한 f456이 A-123 MRR을 거의 설명하지 못해(ρ ≈ 0), T3는 사실상 T1과 같은 모델이 된다.

p = 0.409 / 0.484	9.5%	ρ = 0.07	r = 0.08
주 판정 p (S1 / S2). 8%에서 T3−T1 MSE 차이 1.11 / 0.74 (양수 = T3가 나쁨)	공개 8%에서 T1의 T0(공개 평균) 대비 RMSE 개선 (3.98 → 3.60)	공개 8%, S1 full의 ρ 평균 (25 fold). 소스 예측에 거의 무게를 두지 않음	f456(S1 full) 예측과 A-123 MRR의 상관 (431장, 사후 분석). usage 입력은 0.44

- 2차 판정(T3 대 T2)은 S1·S2 모두 T3가 크게 낮아 "효과 있음"이다. 다만 이는 T2(f456 + 상수)가 T0보다도 크게 나쁘기 때문이며(8% RMSE: T2 S1 6.89, S2 10.40), 소스 모델이 A-123에 쓸모 있다는 뜻은 아니다.
- 보조 판정(전진 검증)과 보조 실험(무작위 공개, δ XGBoost, 라벨 피처)은 실행하지 않았다(8절). 따라서 결론은 주 평가(folds_v1 고정주기 공개)에만 근거한다.
- A-123 MRR의 변동이 작아(변동계수 0.026) 개선 여지 자체가 작다(10절).

2. 실험 설계

표 2-1. 실험 설정

항목	설정
소스	S1 = A-456만 / S2 = A-456 + B-456. 둘 다 수행. 456 라벨은 전부 공개(비대칭 가정)
타깃	A-123 train + val, 이상치 제외 431장
소스 모델 f456	XGBoost (3.2 고정 설정: n_estimators 400, max_depth 4, learning_rate 0.03, subsample 0.8, colsample_bytree 0.8, min_child_weight 3, random_state 42, n_jobs 2). 소스별 456 전체로 1회 학습
f456 입력 2종	full = features_v1 피처 113개 중 since_POLISH_TABLE_w를 뺀 112개(리셋 누락으로 값 오류, #24) / usage = 소모품 사용량 36개 ({mean, std, slope} × 사용량 6개 × s1·s2). 판정은 full, usage는 보고만
평가 분할	folds_v1.csv 25 fold (5-fold × 5회 반복, r = 반복 × 5 + fold). 각 fold의 A-123 학습 쪽에서만 라벨 공개, 평가 쪽으로 채점
공개 비율·방식	2 / 4 / 8 / 16 / 100%. 고정주기 공개: 학습 쪽(N장)을 시간순 정렬, n = 반올림(비율 × N), j번째 위치 = 내림((j + r/25) × N/n)
검정	fold별 평가 쪽 MSE의 쌍별 차이로 Nadeau–Bengio 보정 t-검정 (자유도 24, 평가/학습 비율은 실제 fold 크기, n_train = A-123 학습 쪽 전체). 공개 라벨 수 기준 p는 참고로만 병기

표 2-2. 모델 T0~T3

기호	모델	구성	역할
T0	기준	공개 라벨의 평균 (상수 예측)	하한 기준선, 개선율의 분모
T1	A-123 단독	공개 라벨만으로 GP 학습 (δ와 같은 입력·커널 규칙)	기본값. 주 판정의 비교 대상
T2	소스 + 오프셋	f456(x) + c, c만 공개 라벨로 추정	소스를 그대로 옮긴 경우. 2차 판정의 비교 대상
T3	전이학습	ρ · f456(x) + b + δ(x). ρ·b는 공개 라벨 최소제곱, ρ ∈ [0, 2]로 자른 뒤 b 재추정, 잔차에 δ GP (순차)	검정 대상

표 2-3. fold당 실제 공개 장수와 δ 입력 (25 fold)

공개 비율(%)	fold당 공개 장수: 전체 (최소~최대)	센서 정상 (최소~최대)	δ 입력 개수	등방성 커널 fold	P1_on 포함 fold
2	7.0 (7~7)	2.8 (1~5)	2~2	25 / 25	0 / 25
4	14.0 (14~14)	5.2 (1~9)	2~2	0 / 25	0 / 25
8	28.0 (28~28)	10.2 (5~16)	4~4	0 / 25	0 / 25
16	55.0 (55~55)	21.0 (12~31)	6~6	0 / 25	25 / 25
100	344.8 (344~345)	132.8 (123~141)	6~6	0 / 25	25 / 25

δ 입력 규칙과 GP 커널 (5.4, 5.7)

- δ 후보와 순서: 연마 시작 시각(t_start) → mean_POLISH_TABLE_s1 → mean_DRESSER_s1 → mean_MEMBRANE_s1 → mean_BACKING_FILM_s1 → mean_PSHEET_s1 → mean_DRESSER_TABLE_s1 → P1_on·allzero(한 쌍, 2개로 셈). 이미 들어간 변수와 |스피어만 상관| > 0.9이면 건너뛴다(상관은 fold 학습 쪽 피처 값, MRR 미사용).
- 개수 상한 = max(2, 내림(공개 라벨 수 / 5)). P1_on은 공개 라벨 중 센서 정상이 10장 이상일 때만, 상한이 1개 남았는데 다음이 P1_on·allzero 쌍이면 멈춘다. T1과 T3에 똑같이 적용.
- 공개 8%의 실제 δ 입력: t_start, mean_POLISH_TABLE_s1, mean_DRESSER_s1, mean_MEMBRANE_s1 (25/25 fold). P1_on·allzero 쌍은 어느 fold에도 들어가지 않아 P1_on 포함/제외 비교(5.7-13)는 할 수 없다.
- GP 커널: 공개 10장 이상은 ConstantKernel × RBF(변수별 길이척도) + WhiteKernel, 10장 미만은 RBF 길이척도 1개(등방성). 진폭 0.01~100, 길이척도 0.01~100(표준화 입력), 잡음 1e−3~10, normalize_y, 재시작 5회, random_state = 42 + r. 입력 표준화와 결측 대치(중앙값)는 fold 학습 쪽 전체 웨이퍼 기준.

3. 판정 결과 (공개 8%, f456 입력 full)

표 3-1. 주 판정과 2차 판정. 차이 = 앞 모델 MSE − 뒤 모델 MSE (단위 MRR², 25 fold 평균). 음수 = 앞 모델이 낮음

판정	비교	소스	RMSE (앞 / 뒤 모델)	평균 MSE 차이 (MRR²)	t	p	p (참고: 공개 수 기준)	앞 모델이 낮은 fold	기준 통과
주 판정	T3 − T1	S1	3.760 / 3.605	1.106	0.84	0.409	0.800	8/25	불통과
주 판정	T3 − T1	S2	3.705 / 3.605	0.737	0.71	0.484	0.830	7/25	불통과
2차 판정	T3 − T2	S1	3.760 / 6.886	−33.202	−9.75	8.0e−10	0.007	25/25	통과
2차 판정	T3 − T2	S2	3.705 / 10.404	−94.595	−14.67	1.8e−13	1.6e−04	25/25	통과

기준(5.5, 5.7-16): 평균 MSE 차이 < 0이고 양측 p < 0.05를 S1·S2가 모두 만족할 때만 "효과 있음". p는 n_train = A-123 학습 쪽 전체(fold당 평균 344.8장)로 계산한 판정용 값. 공개 수 기준 p는 판정에 쓰지 않는다.

표 3-2. 최종 판정

판정	S1	S2	최종 판정
주 판정 (T3 대 T1)	**불통과**	**불통과**	**효과 없음 (기본값 T1 유지)**
2차 판정 (T3 대 T2)	통과	통과	효과 있음
보조 판정 (전진 검증 5단계, 8%)	미실행	미실행	미실행 (8절)

표 3-3. 참고: 비율별 평균 MSE 차이 (MRR², f456 full). 8% 외에는 경향만 보고(5.5)

공개 비율(%)	T3 − T1, S1	T3 − T1, S2	T2 − T1, S1	T2 − T1, S2
2	2.80 (p 0.395)	1.23 (p 0.472)	35.08 (p 3.5e−10)	102.36 (p 1.7e−10)
4	0.41 (p 0.611)	0.74 (p 0.475)	30.74 (p 1.2e−09)	95.01 (p 6.6e−15)
8	**1.11 (p 0.409)**	**0.74 (p 0.484)**	**34.31 (p 7.1e−10)**	**95.33 (p 5.9e−13)**
16	1.15 (p 0.236)	0.78 (p 0.299)	36.71 (p 1.1e−10)	96.66 (p 1.1e−12)
100	0.28 (p 0.025)	0.08 (p 0.490)	40.08 (p 9.1e−15)	98.63 (p 7.9e−15)

T2 − T1은 2차 판정과 별개로 보고만 한다. 100%에서 S1의 T3 − T1은 p < 0.05지만 양수(T3가 나쁨)다.

4. 공개 비율별 결과

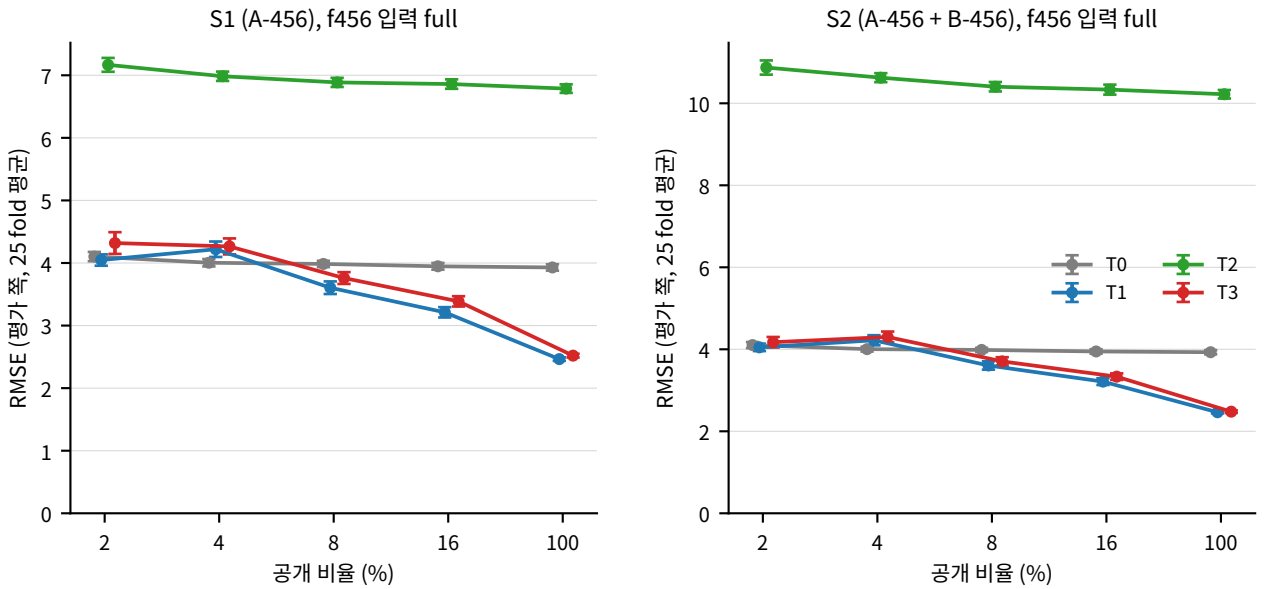


그림 1. 공개 비율 대 평가 쪽 RMSE (f456 입력 full). 점 = 25 fold 평균, 오차 막대 = 표준오차 (표준편차/√25). T0·T1은 소스와 무관해 두 칸이 같다. 가로축은 비율 순서(간격 균등).

표 4-1. 비율별 RMSE·MAE (평균 ± 표준편차, 25 fold, f456 full, 전체 웨이퍼)

공개 비율(%)	모델	S1 RMSE	S1 MAE	S2 RMSE	S2 MAE
2	T0	4.103 ± 0.371	3.258 ± 0.310	4.103 ± 0.371	3.258 ± 0.310
	T1	4.047 ± 0.453	3.207 ± 0.379	4.047 ± 0.453	3.207 ± 0.379
	T2	7.167 ± 0.553	6.004 ± 0.455	10.872 ± 0.866	9.284 ± 0.845
	T3	4.319 ± 0.868	3.450 ± 0.718	4.173 ± 0.638	3.316 ± 0.525
4	T0	4.004 ± 0.293	3.154 ± 0.214	4.004 ± 0.293	3.154 ± 0.214
	T1	4.220 ± 0.617	3.297 ± 0.474	4.220 ± 0.617	3.297 ± 0.474
	T2	6.985 ± 0.372	5.908 ± 0.351	10.625 ± 0.549	9.260 ± 0.711
	T3	4.265 ± 0.639	3.348 ± 0.493	4.301 ± 0.660	3.387 ± 0.513
8	T0	3.985 ± 0.250	3.137 ± 0.196	3.985 ± 0.250	3.137 ± 0.196
	T1	3.605 ± 0.503	2.814 ± 0.405	3.605 ± 0.503	2.814 ± 0.405
	T2	6.886 ± 0.364	5.827 ± 0.361	10.404 ± 0.576	9.235 ± 0.601
	T3	3.760 ± 0.469	2.944 ± 0.361	3.705 ± 0.507	2.893 ± 0.394
16	T0	3.947 ± 0.269	3.114 ± 0.213	3.947 ± 0.269	3.114 ± 0.213
	T1	3.212 ± 0.412	2.531 ± 0.350	3.212 ± 0.412	2.531 ± 0.350
	T2	6.859 ± 0.377	5.827 ± 0.389	10.334 ± 0.609	9.160 ± 0.646
	T3	3.387 ± 0.411	2.665 ± 0.336	3.333 ± 0.398	2.632 ± 0.328
100	T0	3.929 ± 0.254	3.100 ± 0.191	3.929 ± 0.254	3.100 ± 0.191
	T1	2.464 ± 0.140	1.866 ± 0.129	2.464 ± 0.140	1.866 ± 0.129
	T2	6.787 ± 0.341	5.775 ± 0.352	10.221 ± 0.521	9.130 ± 0.526
	T3	2.519 ± 0.150	1.912 ± 0.133	2.479 ± 0.153	1.879 ± 0.137

표 4-2. T0 대비 RMSE 개선율 = (T0 RMSE − 모델 RMSE) / T0 RMSE × 100 (각 RMSE는 25 fold 평균)

공개 비율(%)	T0 RMSE	T1 RMSE	T1 개선율	T3 S1 full	T3 S2 full	T3 S1 usage	T3 S2 usage
2	4.103	4.047	1.4%	−5.3%	−1.7%	−2.1%	0.6%
4	4.004	4.220	−5.4%	−6.5%	−7.4%	1.2%	−0.5%
8	3.985	3.605	9.5%	5.7%	7.0%	10.7%	9.1%
16	3.947	3.212	18.6%	14.2%	15.6%	17.1%	17.2%
100	3.929	2.464	37.3%	35.9%	36.9%	38.0%	37.5%

음수 = T0보다 나쁨. 4%에서는 T1도 T0보다 나쁘다. 4%는 공개 14장으로, 변수별 길이척도 커널이 처음 쓰이는 비율이다(2%는 등방성, 표 2-3).

표 4-3. 참고: f456 입력 usage의 RMSE (평균 ± 표준편차, 보고만). T0·T1은 표 4-1과 같다

공개 비율(%)	T2 S1	T3 S1	T2 S2	T3 S2
2	5.720 ± 0.358	4.191 ± 1.262	7.132 ± 0.525	4.078 ± 0.757
4	5.565 ± 0.274	3.954 ± 0.497	6.971 ± 0.325	4.024 ± 0.469
8	5.561 ± 0.206	3.560 ± 0.461	6.948 ± 0.298	3.622 ± 0.546
16	5.537 ± 0.241	3.271 ± 0.390	6.934 ± 0.304	3.269 ± 0.347
100	5.515 ± 0.245	2.435 ± 0.154	6.911 ± 0.305	2.454 ± 0.154

5. 왜 전이가 안 되는가

T3 = ρ · f456 + b + δ에서 ρ가 0에 가까우면 소스 항이 사라지고 T3는 b + δ, 즉 T1과 같은 구조가 된다. f456 full의 ρ 평균은 S1 0.05~0.13, S2 0.00~0.05이고, 공개 8%에서 ρ = 0에 붙은 fold가 S1 6개, S2 13개다. T3가 T1보다 약간 나쁜 것은 ρ·b를 추정하느라 공개 라벨의 정보를 일부 쓰기 때문으로 보인다.

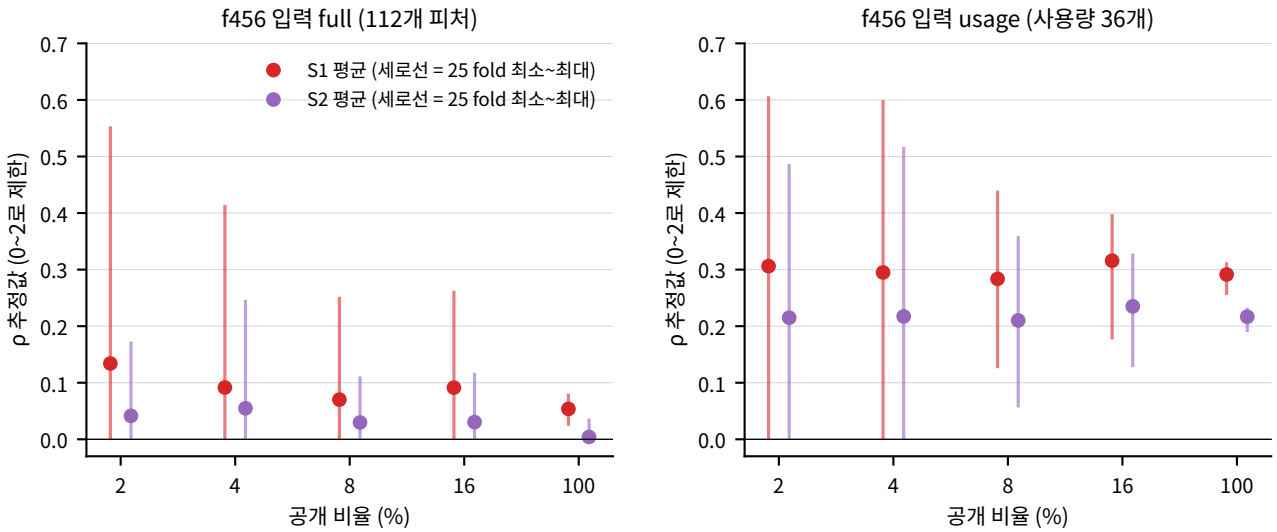


그림 2. T3의 ρ 추정값 분포 (25 fold). 점 = 평균, 세로선 = 최소~최대. ρ는 0~2로 제한(2에 붙은 fold는 없음).

표 5-1. ρ 평균 [최소, 최대] · ρ = 0에 붙은 fold 수 (25 fold)

공개 비율(%)	full S1	full S2	usage S1	usage S2
2	0.134 [0.000, 0.553] · 11	0.041 [0.000, 0.173] · 13	0.306 [0.000, 0.606] · 2	0.215 [0.000, 0.487] · 3
4	0.092 [0.000, 0.414] · 13	0.055 [0.000, 0.247] · 13	0.295 [0.000, 0.600] · 1	0.217 [0.000, 0.517] · 2
8	0.070 [0.000, 0.252] · 6	0.030 [0.000, 0.111] · 13	0.284 [0.126, 0.440] · 0	0.210 [0.056, 0.360] · 0
16	0.091 [0.000, 0.263] · 1	0.030 [0.000, 0.118] · 12	0.316 [0.177, 0.398] · 0	0.235 [0.128, 0.328] · 0
100	0.054 [0.024, 0.081] · 0	0.004 [0.000, 0.037] · 11	0.291 [0.255, 0.313] · 0	0.217 [0.190, 0.233] · 0

표 5-2. f456 예측과 A-123 MRR의 상관 [사후 분석, 판정에 쓰지 않음]

소스	f456 입력	피어슨 r: 전체	센서 정상	센서 전체-0	스피어만: 전체	필요 오프셋 (정상 / 전체-0)
S1	full	0.080 (431장)	0.158 (166장)	0.161 (265장)	0.067	77.4 / 84.9
S1	usage	0.444 (431장)	0.494 (166장)	0.396 (265장)	0.379	78.8 / 77.8
S2	full	0.002 (431장)	−0.024 (166장)	0.141 (265장)	0.056	70.9 / 83.4
S2	usage	0.417 (431장)	0.465 (166장)	0.371 (265장)	0.378	75.6 / 73.7

출처: results/diagnostics/2026-11-01_김혜연_t2_decomposition.csv의 all_wafers 행(A-123 431장, f456는 fold와 무관). 필요 오프셋 = 부분집합별 평균(MRR − f456). 이 표는 판정(PR #25) 이후 원인 확인용으로 만든 것이다.

- f456 full과 A-123 MRR의 상관은 전체 0.08, 센서 정상 0.16로 낮다. 사용량만 쓴 usage는 0.44로 높지만, 공개 8%에서 T3 − T1은 S1 −0.36 (p 0.716), S2 0.17 (p 0.880)로 차이가 없다. 사용량 정보는 T1의 δ 입력(t_start, 사용량 s1 평균)에 이미 들어 있기 때문으로 보인다.
- T2가 크게 나쁜 이유: 센서 정상과 전체-0 웨이퍼에서 필요한 오프셋이 다르다(S1 full 77.4 대 84.9). f456은 456에 없는 전체-0 패턴의 입력에서 다른 값을 내므로 상수 c 하나로는 맞출 수 없다. T3는 ρ를 0 가까이 줄여 이 문제를 피한다.
- S1 대 S2 (관찰만, 5.0 해석 제한): S2 full은 상관이 0.00로 S1보다 낮고, 8% ρ 평균 0.03(S1 0.07), T2 RMSE 10.40(S1 6.89)다. 같은 스테이지(A)만 쓴 소스가 A-123과 조금 더 비슷하지만, 카운터가 장비 전체에서 공유되므로(5.0) "같은 부품 공유"의 근거로 쓰지 않는다. T3 기준으로는 두 소스 모두 T1과 차이가 없다.

6. 불확실성: 90% 예측구간 포함률

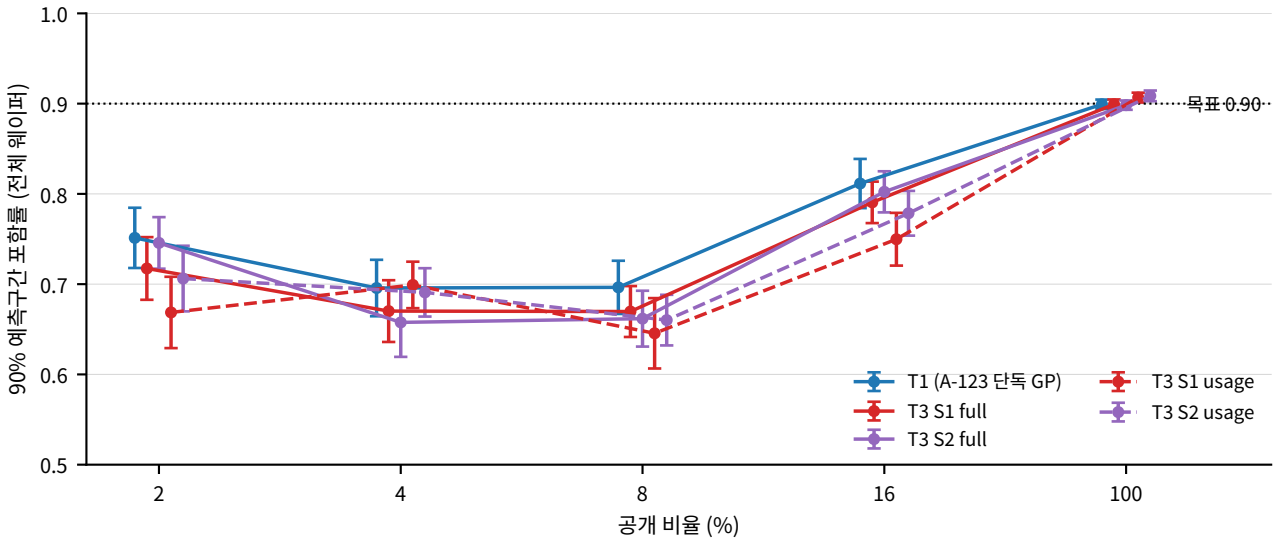


그림 3. T1·T3의 90% 예측구간 포함률 대 공개 비율 (전체 웨이퍼). 점 = 25 fold 평균, 오차 막대 = 표준오차. 구간은 WhiteKernel 잡음을 포함한 관측 예측구간이며 f456·ρ·b의 불확실성은 무시한다(5.7-10).

표 6-1. 90% 예측구간 포함률 (평균 ± 표준편차, 25 fold, 목표 0.90)

공개 비율(%)	T1	T3 S1 full	T3 S2 full	T3 S1 usage	T3 S2 usage
2	0.751 ± 0.167	0.717 ± 0.174	0.746 ± 0.143	0.669 ± 0.198	0.706 ± 0.182
4	0.696 ± 0.156	0.670 ± 0.171	0.658 ± 0.191	0.699 ± 0.129	0.691 ± 0.134
8	0.696 ± 0.147	0.670 ± 0.141	0.662 ± 0.155	0.646 ± 0.195	0.660 ± 0.140
16	0.811 ± 0.136	0.791 ± 0.115	0.802 ± 0.114	0.750 ± 0.146	0.779 ± 0.124
100	0.899 ± 0.026	0.899 ± 0.027	0.898 ± 0.026	0.907 ± 0.027	0.909 ± 0.030

공개 2~8%에서 포함률은 0.646~0.751로 목표 0.90보다 낮다(구간이 너무 좁음). 16%에서 0.750~0.811, 100%에서 0.898~0.909가 된다. 공개 라벨이 적을 때 GP 잡음이 하한(1e−3) 가까이 추정되는 fold가 많은 것(9절)과 같은 방향이다.

7. 웨이퍼 유형별 오차 (공개 8%, f456 full)

표 7-1. 웨이퍼 유형별 RMSE (평균 ± 표준편차, 25 fold)

웨이퍼	fold당 평가 장수	T0	T1	T2 S1	T3 S1	T2 S2	T3 S2
전체	86.2	3.985 ± 0.250	3.605 ± 0.503	6.886 ± 0.364	3.760 ± 0.469	10.404 ± 0.576	3.705 ± 0.507
센서 정상	33.2	4.099 ± 0.397	3.421 ± 0.688	7.227 ± 0.851	3.610 ± 0.626	11.911 ± 1.402	3.556 ± 0.646
전체-0	53.0	3.915 ± 0.330	3.699 ± 0.470	6.588 ± 0.697	3.835 ± 0.478	9.210 ± 1.080	3.781 ± 0.521

센서 정상 = 전체-0 센서가 없는 웨이퍼, 전체-0 = 압력·유량·회전 센서 중 하나 이상이 웨이퍼 전체에서 0. 분해는 보고만 한다(5.7-16, 검정 대상은 전체 웨이퍼).

표 7-2. 비율별 웨이퍼 유형 RMSE (25 fold 평균, f456 full)

공개 비율(%)	정상: T1	정상: T3 S1	정상: T3 S2	전체-0: T1	전체-0: T3 S1	전체-0: T3 S2
2	4.160	4.586	4.395	3.956	4.125	3.999
4	4.317	4.373	4.473	4.112	4.142	4.131
8	**3.421**	**3.610**	**3.556**	**3.699**	**3.835**	**3.781**
16	3.062	3.287	3.232	3.292	3.432	3.383
100	2.412	2.478	2.430	2.489	2.538	2.503

공개 8%에서 T1 RMSE는 센서 정상 3.42, 전체-0 3.70다. T3는 두 유형 모두 T1보다 약간 높아, 어느 유형에서도 전이 이득이 없다.

8. 보조 판정과 보조 실험

표 8-1. 보조 판정·보조 실험 실행 여부

항목	사전 등록	상태
보조 판정: 시간순 전진 검증 5단계 (각 단계 8% 공개, T3가 T1보다 낮은 단계 수)	5.2, 5.5	미실행
무작위 공개 (fold마다 시드 42 + r)	5.3	미실행
δ를 XGBoost로 바꾼 T1·T3	5.4 보조	미실행
라벨 피처 보조 실험 (T1·T3, 2~100%, 경향만)	5.6	미실행

- 결과 파일이 없어 수치를 보고하지 않는다. 5.7-17의 일정상 전진 검증·무작위 공개는 11/1 이후 2차 면담 전, δ XGBoost·라벨 피처 실험은 2차 면담 이후에 한다.
- 5.2는 주 평가와 보조 평가를 결과표에 나란히 보고하도록 정했다. 보조 평가가 없으므로, 주 판정 결과가 "이웃 시점 정보 덕분"인지 확인하지 못한 상태다. 다만 주 판정이 이미 "효과 없음"이라 기본값(T1)은 바뀌지 않는다.

9. 실행 신뢰도

표 9-1. GP 최적화 경고 건수 (주 결과 csv의 gp_warn_t1·gp_warn_t3)

공개 비율(%)	T1 경고 건수	T1 경고 fold	T3 경고 건수	T3 경고 칸 (fold × 소스 × 입력)
2	8	8 / 25	45	42 / 100
4	18	16 / 25	88	74 / 100
8	41	22 / 25	173	96 / 100
16	62	23 / 25	245	96 / 100
100	61	24 / 25	263	98 / 100
합계	**190**		**814**	

T1은 fold당 1회 학습(비율당 25회), T3는 fold × 소스 2 × 입력 2마다 1회(비율당 100회). 경고가 나도 결과는 그대로 썼다(5.7-15).

표 9-2. GP 경고 종류 (공개 2~16%, 경고 메시지 기준)

경고 종류 (하이퍼파라미터가 붙은 경계)	2%	4%	8%	16%	합계	비율
길이척도 상한	0	36	177	293	506	74.4%
잡음 하한	31	61	37	12	141	20.7%
길이척도 하한	19	8	0	2	29	4.3%
진폭 하한	3	1	0	0	4	0.6%
합계	**53**	**106**	**214**	**307**	**680**	**100%**

출처: results/diagnostics/2026-11-01_김혜연_gp_warnings.csv (같은 설정으로 다시 학습해 메시지를 기록, 주 결과와 지표 최대 차이 3e-14, 건수 일치). 모두 sklearn ConvergenceWarning(값이 탐색 경계 근처)이며 최적화 실패(lbfgs 비수렴)는 없다. 공개 100%의 경고(T1 61건, T3 263건)는 종류를 기록하지 않았다. 길이척도 상한(100)은 그 δ 입력이 사실상 쓰이지 않는다는 뜻이고, 잡음 하한은 공개 라벨이 적을 때 GP가 라벨을 그대로 통과하려 한다는 뜻이다.

표 9-3. 시드·환경·실행 명령

항목	값
시드	f456 random_state = 42 / GP random_state = 42 + r (r = 반복 × 5 + fold), 재시작 5회도 이 시드에서 시작. 고정주기 공개는 시드 없음(5.3 공식)
패키지	python 3.13.2 · numpy 2.5.3 · pandas 3.0.6 · scipy 1.18.1 · scikit-learn 1.9.1 · xgboost 3.2.0 (xgboost 버전이 다르면 코드가 멈춤, 5.7-11)
f456 스레드	n_jobs = 2 고정 (subsample < 1이면 스레드 수에 따라 결과가 달라짐, #23)
실행	커밋 9947b4c (main), 2026-11-01 17:29:54 시작, 1398초. CPU 12th Gen Intel(R) Core(TM) i7-12650H, Windows-11-10.0.26200-SP0
실행 명령	python src/a123_transfer.py → 주 결과 4종 / python src/diagnostics/gp_warnings_a123.py → 경고 종류 / python src/diagnostics/t2_decomposition_a123.py → 상관·오프셋 / python src/report_a123_transfer.py → 이 보고서
입력 해시 (sha256 앞 16자리)	features_v1 31aefa89f84aa209 · folds_v1 e4b364141b0bdaa9 · reveal_masks_v1 00d9ed3ef9436450 · wafer_table 3aaf498e8562d6e8 (주 결과 yaml)

10. 한계

- A-123 MRR의 변동이 작다: 431장 평균 151.2, 표준편차 3.93, 변동계수 0.026. 가장 좋은 T1(100% 공개)도 RMSE 2.46로 T0 대비 37.3% 개선에 그치며, 8%에서는 RMSE 차이가 0.38다. 작은 차이를 가려내기 어려운 조건이다.
- 데이터가 PHM 2016 한 개이고 A-123은 한 장비의 한 챔버군이다. 다른 장비·레시피로 일반화할 수 없다.
- 압력·회전·유량의 단위와 공정 레시피가 공개되지 않아, f456이 A-123에서 맞지 않는 이유(레시피 차이, 센서 결측 패턴)를 물리적으로 확인할 수 없다. A-123 431장 중 265장이 센서 전체-0 웨이퍼다.
- 90% 예측구간은 δ GP의 잡음만 반영하고 f456·ρ·b의 추정 불확실성을 무시한다(5.7-10). 공개 2~16%의 포함률이 목표보다 낮다.
- GP 경고가 많다(공개 2~16%에서 680건, 전체 비율 합계 1004건). 대부분 길이척도가 상한에 붙은 경우로, 그 입력이 쓰이지 않는다는 뜻이라 결과를 무효로 만들지는 않지만 하이퍼파라미터 추정이 불안정함을 보여 준다.
- 보조 판정(전진 검증)과 보조 실험이 미실행이라 결론은 주 평가에만 근거한다(8절). 5절의 상관·오프셋 분석은 사후 분석이다.